CONTA COMIGO · ESTUDO DE PRODUTO

Vozes humanizadas estudo v2

Pesquisa de modelos de voz mais humanas para o jogo: vozes gratuitas "Online (Natural)" do Edge, níveis Enhanced/Premium da Apple, síntese neural no navegador via WebAssembly (Piper, Kokoro), nuvem sob a lente COPPA/LGPD-K — e o que a versão 2.6.0 implementou de imediato.

Outubro de 2026 · Versão implementada: 2.6.0

Produto: Conta Comigo — Matemática para Crianças (extensão Chromium + Firefox)

Sumário

1. Sumário executivo 2

2. O que torna uma voz "humana" para uma criança 2

3. Inventário: o que o navegador já oferece hoje 3

3.1 Microsoft Edge — vozes "Online (Natural)" gratuitas 3

3.2 Apple (iPhone, iPad e Mac) — níveis Enhanced e Premium 3

3.3 Android — Google Speech Services e Samsung 3

3.4 Quadro-resumo das fontes de voz no navegador 3

4. Síntese neural 100% no navegador (WASM) — o próximo passo 4

5. Vozes em nuvem — por que não agora 5

6. O que foi implementado na v2.6.0 5

6.1 Detector de qualidade em camadas com curadoria PT/EN/ES 5

6.2 Interface dos responsáveis: lista agrupada, nota de voz ativa e guia 6

6.3 Responsividade multi-telas (pedido paralelo da v2.6.0) 6

7. Recomendações e roteiro 7

8. Metodologia e fontes 7

1. Sumário executivo

Este documento responde ao pedido de **pesquisar mais modelos de vozes que possam ser utilizados no Conta Comigo, com foco em vozes mais humanizadas**, e registra o que foi imediatamente implementado na versão 2.6.0. A pesquisa cobriu três frentes complementares: as vozes que o próprio navegador já expõe pela Web Speech API (incluindo as vozes gratuitas "Online (Natural)" do Microsoft Edge e os níveis Enhanced/Premium da Apple), os modelos de síntese neural que rodam integralmente no navegador via WebAssembly (Piper e Kokoro-82M) e os serviços de voz em nuvem (ElevenLabs, Azure Neural e Google Cloud TTS). Para cada frente foram avaliadas qualidade sonora, custo, privacidade — critério inegociável em um aplicativo infantil sob COPPA/LGPD-K/GDPR-K — e viabilidade técnica dentro de uma extensão Manifest V3 e de um PWA para Android.

A conclusão principal é que **hoje já é possível soar consideravelmente mais humano sem custo algum e sem enviar nenhum dado para fora do dispositivo**: a chave está em detectar e priorizar as vozes neurais que os sistemas operacionais e navegadores já trazem, orientar os responsáveis a instalar as vozes de melhor qualidade de cada plataforma e manter o motor de prosódia próprio do jogo. Foi exatamente isso que a v2.6.0 entrega: camadas de qualidade de voz com curadoria para português, inglês e espanhol, lista agrupada por qualidade na área dos responsáveis, nota indicando qual voz está ativa e um guia prático de instalação de vozes por plataforma. Os modelos WASM ficam documentados como caminho recomendado para a v3.x, quando o modo Android/PWA permitir baixar um modelo neural opcional de 20 a 60 MB.

2. O que torna uma voz "humana" para uma criança

A sensação de humanidade em uma voz sintética vem de três pilares combinados. O primeiro é a **prosódia neural**: modelos treinados com horas de fala humana geram entonação, respiração e microvariações de duração que motores formantizados clássicos (eSpeak, Pico, Festival) não conseguem reproduzir — é a diferença entre ouvir uma pessoa lendo uma história e ouvir um robô soletrando palavras. O segundo pilar é a **segmentação contextual**: dividir o texto em segmentos com pausas proporcionais à pontuação, técnica já implementada no jogo desde a v2.4 (A-177), que melhora qualquer voz, inclusive as padrão. O terceiro pilar é a **adequação ao público**: para crianças de 4 anos, a pesquisa do 1º estudo (v2.4) e a literatura de desenho de áudio infantil convergem em voz de timbre acolhedor, velocidade 5 a 15% abaixo do padrão e tom levemente elevado — parâmetros que o jogo expõe por perfil (vRate/vPitch) e aplica com calma extra na repetição de questões.

Um detalhe prático descoberto na pesquisa e confirmado por catálogos independentes de vozes (repositório web-speech-recommended-voices): várias vozes "Online (Natural)" da Microsoft **não aceitam ajuste de tom** (pitchControl falso), pois o modelo neural fixa a entonação natural. O jogo já é tolerante a isso — o tom configurado é simplesmente ignorado por essas vozes, e a velocidade continua funcionando, o que preserva a experiência do responsável sem exigir código especial.

> *Para o público infantil, a voz ideal não é apenas a mais realista em laboratório: é a que mantém entonação acolhedora de forma consistente, não falha offline no meio da rodada e não expõe nenhum dado da criança.*

3. Inventário: o que o navegador já oferece hoje

3.1 Microsoft Edge — vozes "Online (Natural)" gratuitas

O Edge expõe pela mesma API speechSynthesis as vozes neurais da Microsoft identificadas como "Online (Natural)" — para o português do Brasil, as vozes de destaque são Thalita e Antonio (exemplo do nome completo reportado pelo navegador: "Microsoft Thalita Online (Natural) - Portuguese (Brazil)"). São as vozes de melhor qualidade disponíveis sem custo em qualquer desktop, exigem apenas conexão com a internet e voltam automaticamente às vozes locais quando o dispositivo fica offline. Como o jogo já tem caminho B de fallback silencioso para voz local (v2.4), usar o Conta Comigo no Edge é hoje a forma mais simples de obter narração humana — e virou a primeira recomendação do guia dentro do aplicativo.

3.2 Apple (iPhone, iPad e Mac) — níveis Enhanced e Premium

A documentação oficial da Apple (AVSpeechSynthesisVoiceQuality) define três níveis: default, enhanced e premium — os dois últimos precisam ser baixados manualmente pelo responsável, em Ajustes, Acessibilidade, Conteúdo falado, Vozes (iOS) ou no VoiceOver Utility (macOS). Baixar a voz Enhanced/Premium do idioma da criança transforma visivelmente a narração do jogo em dispositivos da Apple, e a voz aparece normalmente na lista do sistema com o nome do idioma (por exemplo, Luciana para o português). O detector implementado na v2.6.0 reconhece os rótulos "enhanced" e "premium" e os coloca na camada máxima.

3.3 Android — Google Speech Services e Samsung

No Android, a qualidade depende do motor instalado. O aplicativo de sistema "Voz do Google" (Speech Recognition & Synthesis, pacote com.google.android.tts) fornece vozes de boa qualidade para o português e permite baixar variantes melhores por idioma; o caminho recomendado no guia é atualizar o app pela Play Store e, em Configurações, Acessibilidade, Saída de texto para fala, escolher e baixar as vozes de melhor qualidade. Fabricantes como a Samsung fornecem motores próprios. O PWA do jogo (v2.5) herda automaticamente o motor padrão do sistema, e o detector de camadas classifica as vozes Google e Samsung na camada intermediária de rede quando não há rótulo neural explícito.

3.4 Quadro-resumo das fontes de voz no navegador

Fonte	Qualidade	Offline	Custo	Como o jogo trata (v2.6)
Edge "Online (Natural)"	Excelente (neural)	Não (fallback local)	Grátis	Camada máxima com prioridade alta; exemplo citado no guia interno (Thalita/Antonio)
Apple Enhanced/Premium	Excelente	Sim	Grátis	Camada máxima; guia ensina a baixar em Ajustes/VoiceOver Utility
Google de rede (Chrome/Android)	Boa a ótima	Não	Grátis	Camada intermediária; detectada pela marca na lista do sistema
Vozes locais padrão do sistema	Regular	Sim	Grátis	Camada padrão; usadas como fallback silencioso em caso de falha de rede
Motores robóticos (eSpeak, Pico, Festival, Compact)	Baixa	Sim	Grátis	Penalizados na heurística e agrupados como "básicas" no fim da lista

Tabela 1 — Fontes de voz disponíveis pela Web Speech API, por plataforma

4. Síntese neural 100% no navegador (WASM) — o próximo passo

A pesquisa confirmou que já existe um ecossistema maduro de modelos neurais que rodam dentro do próprio navegador via WebAssembly, sem servidor e sem custo de API. O **Piper**, compilado para WASM (projetos vits-web da diffusionstudio, piper-tts-web da Mintplex Labs e o clássico leitor read-aloud), gera voz com qualidade claramente superior aos motores locais clássicos, tem voz em português do Brasil (pt_BR-faber-medium) e licença MIT; cada voz ocupa de 20 a 60 MB baixados uma única vez e depois cacheados. O **Kokoro-82M** (82 milhões de parâmetros, licença Apache 2.0, biblioteca kokoro-js sobre Transformers.js) impressiona pela qualidade — variante quantizada de apenas 86 MB, aceleração via WebGPU quando disponível — mas, na versão atual, não tem voz nativa em português, o que o exclui como voz principal do jogo por enquanto.

Para o Conta Comigo, a integração WASM é tecnicamente viável nos dois formatos: na extensão MV3, dentro de um documento offscreen ou worker com o modelo empacotado opcionalmente; no PWA Android, com download do modelo sob demanda e cache pelo service worker, de forma análoga ao que projetos como StreamingKokoroJS já fazem. Os custos são conhecidos e administráveis: download inicial de dezenas de megabytes, memória extra durante a inferência e maior consumo de bateria em sessões longas — razões pelas quais a recomendação é oferecer isso como uma **"voz premium offline" opcional**, instalada pelo responsável, e não como padrão. Essa é a peça central da onda 3 do roteiro (seção 7).

Modelo/projeto	Licença	Tamanho típico	pt-BR	Papel recomendado no Conta Comigo
Piper (vits-web / piper-tts-web)	MIT	20–60 MB por voz	Sim (pt_BR-faber-medium)	Voz premium offline opcional na v3.x, instalada pelo responsável no PWA/Android
Kokoro-82M (kokoro-js)	Apache 2.0	86 MB (q8) a 326 MB	Não nativo	Reavaliar quando o projeto publicar vozes pt-BR; referência de qualidade
StreamingKokoroJS (referência)	Apache 2.0	idem Kokoro	Não	Referência de arquitetura: workers, streaming por blocos e cache do modelo

Tabela 2 — Modelos de síntese neural que rodam no navegador (WASM)

5. Vozes em nuvem — por que não agora

Os serviços de nuvem testados na pesquisa (ElevenLabs, Azure Neural e Google Cloud TTS) oferecem hoje a melhor qualidade absoluta do mercado — para o português do Brasil, catálogos chegam a listar mais de duzentas vozes neurais, incluindo as Azure Francisca e Antonio que inspiram a curadoria do jogo. Ainda assim, a recomendação deste estudo é **não integrá-los nesta fase**, por três razões independentes entre si. Primeiro, privacidade: enviar o texto das perguntas e recompensas para servidores de terceiros quebra o princípio local-first que sustenta o envelope de conformidade COPPA/LGPD-K/GDPR-K do produto e exigiria consentimento parental explícito, política de dados detalhada e auditoria de subprocessadores. Segundo, custo operacional contínuo por caractere, inviável para um uso doméstico gratuito e repetitivo. Terceiro, dependência de rede: a experiência infantil não pode depender de latência de API para narrar uma continha.

Resta um cenário futuro legítimo: um modo opcional "narração em nuvem" no PWA Android, ativado apenas pelo responsável com consentimento explícito, usando uma chave própria e limite de uso — avaliado apenas se a demanda real justificar. Até lá, as vozes "Online (Natural)" do Edge entregam, de graça e sem servidor próprio do projeto, praticamente a mesma classe de qualidade que a nuvem cobraria para gerar.

6. O que foi implementado na v2.6.0

6.1 Detector de qualidade em camadas com curadoria PT/EN/ES

A heurística da v2.4 foi reescrita como um sistema de camadas. A camada máxima identifica os rótulos de síntese neural de topo ("Online (Natural)", natural, neural, studio, premium, enhanced); a camada intermediária reconhece vozes de rede e marcas (Google, Microsoft, Apple/Siri, Samsung); a camada padrão cobre as vozes locais comuns; e a camada básica rebaixa motores notoriamente robóticos (eSpeak, Pico, Festival, CMU, Compact) na pontuação e na exibição. Sobre as camadas atua uma curadoria de nomes — vozes reconhecidamente acolhedoras para o público, como Thalita, Francisca, Luciana, Yara, Joana, Aria, Jenny, Elvira e Dália, recebem prioridade extra —, de modo que, entre duas vozes equivalentes, o jogo escolha a que tende a soar melhor para uma criança. A escolha manual do responsável continua vencendo a heurística, e o fallback silencioso para voz local em falha de rede foi preservado sem alteração.

6.2 Interface dos responsáveis: lista agrupada, nota de voz ativa e guia

A lista de vozes nas opções passou a ser renderizada em grupos por qualidade (naturais recomendadas primeiro, depois neurais/de rede, padrão e básicas), com escape de nomes do sistema que contenham caracteres especiais. Uma nota em texto indica em tempo real qual voz está ativa e com qual camada — por exemplo, "Voz ativa: natural (Microsoft Thalita Online (Natural))" —, eliminando a dúvida mais comum dos responsáveis: se a voz selecionada é de fato a boa. O novo guia embutido "Como deixar a voz mais humana (grátis)" traz, em cinco linhas, o caminho exato por plataforma: usar o Edge com as vozes Online (Natural); instalar vozes neurais no Windows pelo Narrador/Configurações; atualizar e baixar vozes no Android pelo app Voz do Google; baixar vozes Enhanced/Premium em iPhone, iPad e Mac; e instalar o Piper como módulo do speech-dispatcher no Linux. Todo o texto e os rótulos foram traduzidos para os três idiomas do jogo.

Camada	Critério de reconhecimento	Exemplos	Tratamento
Natural	Online (Natural), natural, neural, studio, premium, enhanced	Thalita (Edge), Enhanced/Premium (Apple)	Primeiro grupo da lista; maior prioridade na escolha automática
Neural/rede	Google, Microsoft, Apple, Samsung, Siri, multilingual	Google português do Brasil	Segundo grupo; usadas quando não há camada natural
Padrão	Vozes locais comuns do sistema	Luciana local, SAPI5	Terceiro grupo; fallback offline do caminho B
Básica	eSpeak, Pico, Festival, CMU, Compact	eSpeak NG	Fim da lista com rótulo próprio; só usadas se não houver alternativa

Tabela 3 — Camadas de qualidade implementadas no motor de voz (v2.6.0)

6.3 Responsividade multi-telas (pedido paralelo da v2.6.0)

No mesmo ciclo foi entregue a adaptação da interface a qualquer tela, pré-requisito para o uso no Android: media queries progressivas de 320 a 1500 pixels, herói da tela inicial que empilha em telas estreitas, tipografia fluida com clamp para equação, respostas e títulos, modo paisagem compacto para altura abaixo de 500 pixels, suporte a dvh e safe-area (notch e barra de gestos) no PWA e alvos de toque de pelo menos 44 pixels com touch-action de manipulação. O conjunto foi verificado em navegador headless em seis resoluções, sem transbordo horizontal em nenhuma delas — 320, 360, 768, 844 por 390 em paisagem, 1440 e 1920 pixels.

7. Recomendações e roteiro

Onda 1 — entregue na v2.6.0: detector em camadas com curadoria, lista agrupada, nota de voz ativa e guia por plataforma; nenhuma dependência nova, zero custo e nenhum dado fora do dispositivo. Onda 2 — v2.7.x: botão de prévia por voz na lista agrupada (ouvir a mesma frase em duas vozes antes de escolher), memorização da "voz preferida" por criança com sugestão automática quando uma voz de camada superior aparecer no sistema e teste comparativo A/B dos parâmetros de velocidade e tom por faixa etária. Onda 3 — v3.x: voz premium offline opcional via Piper WASM no PWA Android, com download guiado de 20 a 60 MB, indicador de espaço disponível e desinstalação limpa; reavaliar Kokoro caso o projeto publique vozes nativas em português; manter nuvem fora do escopo enquanto o modo local atender.

Regra de ouro do produto: toda melhoria de voz precisa passar pelo tripé — soa humana, funciona offline e não envia nada da criança para fora do aparelho.

8. Metodologia e fontes

A pesquisa foi conduzida em fontes públicas recentes: repositório web-speech-recommended-voices (catálogo colaborativo de vozes recomendadas por navegador, com metadados de controle de tom e velocidade), documentação oficial da Apple para AVSpeechSynthesisVoiceQuality, páginas da Microsoft e catálogos independentes sobre as vozes "Online (Natural)" do Edge, páginas oficiais de suporte do Google sobre saída de texto para fala no Android, e os projetos Piper (incluindo a integração com speech-dispatcher em Linux, que faz as vozes aparecerem como locais no Chrome), piper-tts-web (MIT), kokoro-js e StreamingKokoroJS (Apache 2.0) para a frente WASM. A implementação foi validada por QA automatizado em navegador headless: agrupamento de camadas com vozes simuladas de todas as classes, mensagem de ausência de vozes, guia nos três idiomas e medições de layout em seis resoluções, com console limpo em todas as páginas.