Sumário

1. Sumário executivo 2

2. Diagnóstico da voz atual 2

3. O que torna uma voz humana e cordial 3

4. Caminho A - Aprimorar a voz local (recomendado na v2.4) 4

5. Caminho B - Vozes neurais do sistema (grátis, sem código novo) 4

6. Caminho C - Síntese em nuvem (adiar para a era v3.x) 5

7. Caminho D - Áudio humano pré-gravado (o calor máximo) 6

8. Recomendação, riscos e próximos passos 6

1. Sumário executivo

O público do Conta Comigo é formado por crianças a partir de quatro anos e adolescentes, uma faixa em que a voz do aplicativo não é um detalhe de acabamento: ela é a principal companheira de aprendizagem. Quem ainda não lê com fluência depende inteiramente da narração para entender a pergunta, perceber que errou de forma tranquila e celebrar a conquista. Este estudo responde à pergunta colocada pelos responsáveis pelo produto: existe possibilidade de acrescentar uma voz mais humana, com tom mais cordial? A resposta é sim, e existem quatro caminhos técnicos complementares para chegar lá, com custos, riscos e esforços muito diferentes.

O caminho A aprimora o motor já presente no aplicativo, a Web Speech API do navegador, com escolha automática de vozes naturais, prosódia emulada por pontuação e uma biblioteca de falas afetuosas. O caminho B aproveita vozes neurais que o próprio sistema operacional oferece gratuitamente. O caminho C avalia a síntese em nuvem (Google, Microsoft, Amazon e ElevenLabs), com melhor qualidade acústica porém custos recorrentes, dependência de rede e exigências de privacidade próprias de um produto infantil. O caminho D propõe áudio humano pré-gravado para as frases centrais do jogo, o auge do calor humano, com latência zero e funcionamento offline.

A recomendação é uma trilha em três fases: implementar o caminho A na v2.4 (custo zero, privacidade intacta), oferecer o pacote gravado do caminho D como opção na v2.5 e reservar a nuvem do caminho C para a era v3.x, apenas com consentimento dos responsáveis e com as chaves de API protegidas em um servidor. Ao final, o aplicativo ganha uma voz que acolhe, elogia com conteúdo específico e nunca humilha, sem abrir mão dos três pilares atuais: gratuito, offline e privado.

2. Diagnóstico da voz atual

Desde a v2.0 o Conta Comigo narra perguntas e feedbacks com a API speechSynthesis do navegador, uma síntese local que funciona sem internet e sem custo. O motor atual expõe controles honestos na área dos responsáveis: velocidade, tom, volume e escolha manual da voz do sistema. Os valores padrão já foram pensados para crianças (velocidade 0,95 e tom 1,15, levemente agudo), e o idioma da narração acompanha a interface em português, inglês e espanhol. É uma base sólida: zero permissões de rede, zero dados enviados e funcionamento idêntico em qualquer computador com navegador moderno.

As limitações, porém, são sentidas na escuta. A qualidade acústica depende inteiramente da voz que o sistema operacional instala: em máquinas sem vozes modernas, a narração soa robótica e entediante, com entonação plana que não distingue pergunta de festa. A seleção automática pega a primeira voz portuguesa encontrada, que raramente é a mais bonita do sistema. As frases de elogio e incentivo são curtas e pouco variadas, e não há pausas prosódicas planejadas, de modo que frases compostas saem corridas. Nada disso exige trocar de tecnologia: são melhorias que cabem no motor atual, e é exatamente por onde o caminho A começa.

Aspecto	Hoje (v2.3)	Proposta (v2.4)
Velocidade	0,95 fixa, ajustável	0,90 para perfis até 6 anos; ajustável por perfil
Tom	1,15 fixo, ajustável	Manter 1,15; ajuste por perfil na loja/ajustes
Seleção de voz	Primeira voz do idioma	Heurística que prefere vozes naturais/neurais
Prosódia	Frase única corrida	Pausas por pontuação e frases divididas
Elogios	5 frases genéricas	Biblioteca contextual com dezenas de falas
Empatia no erro	Frases neutras	Falas de acolhimento sem julgamento

Tabela 1. Parâmetros da narração: estado atual e proposta

3. O que torna uma voz humana e cordial

Humanidade, em síntese de voz, é menos uma propriedade acústica e mais uma experiência de conversa. Três ingredientes dominam a percepção: prosódia expressiva (a melodia da frase, com subidas em perguntas e descidas em afirmações), ritmo adequado à idade (crianças pequenas processam fala melhor quando ela é cerca de dez a vinte por cento mais lenta que a conversa adulta) e calor afetivo (vocabulário carinhoso, elogios específicos e paciência diante do erro). Uma voz com timbre sintético, mas com boa prosódia e atitude afetuosa, é percebida como mais humana do que uma voz acusticamente perfeita que lê tudo no mesmo tom.

Para o público específico do Conta Comigo, somam-se três princípios de design. Primeiro, reforço positivo com conteúdo: dizer exatamente o que foi bom (que resposta rápida, você contou todos os morangos) ensina mais que um simples muito bem, e a literatura de feedback educacional é consistente quanto a isso. Segundo, erro tratado como parte do caminho: a voz deve acolher, sugerir tentar de novo e jamais soar decepcionada; sarcasmo, ironia e tom de cansaço são proibidos por padrão editorial. Terceiro, identidade de personagem: a raposa da mascote pode ganhar uma voz fixa, apresentada às crianças como uma amiga que brinca de contar junto, o que aumenta o vínculo e a constância entre dispositivos.

Há ainda um cuidado de inclusão que o estudo recomenda transformar em regra: afeto não é volume emocional máximo. Crianças autistas, com transtornos de processamento auditivo ou simplesmente mais sensíveis podem preferir entonação calma. Por isso os ajustes manuais de velocidade, tom e voz existentes continuam acessíveis, e a biblioteca de falas terá variações calmas por padrão, com intensidade festiva reservada a marcos grandes, como subir de nível ou vencer o desafio-chefe.

4. Caminho A - Aprimorar a voz local (recomendado na v2.4)

O primeiro pacote de melhorias não adiciona nenhuma dependência: é engenharia carinhosa sobre a API que já usamos. A peça central é uma heurística de seleção automática de voz. Hoje o app pega a primeira voz do idioma; a proposta é ranquear todas as vozes portuguesas do sistema por uma pontuação: nomes que contêm Natural, Neural ou Online recebem bônus grande; nomes com Google ou Microsoft recebem bônus médio; vozes Locais ganham preferência de estabilidade; e a escolha manual do responsável sempre vence a heurística. No Microsoft Edge e em sistemas bem equipados, essa heurística sozinha já eleva a narração a vozes neurais de qualidade comercial, sem custo algum.

A segunda peça é prosódia emulada. A Web Speech API não suporta SSML (a linguagem de marcação de fala) nos navegadores atuais, mas a pontuação comum produz pausas reais: vírgula pausa pouco, ponto pausa mais, reticências criam suspense e interrogação levanta a entonação. O motor passará a formatar as falas pensando nisso e, para frases compostas, a enfileirar duas ou três utterances com pausas calculadas entre elas, algo que o objeto de fala já permite fazer em sequência. O resultado é uma narração com respiração, em vez do bloco contínuo atual.

A terceira peça é a biblioteca de falas cordiais, ampliada e contextual. Em vez de cinco elogios genéricos, dezenas de frases organizadas por situação: acerto com muita rapidez, combo, acerto depois de errar (valorizando a persistência), fim de rodada com recorde, subida de nível, incentivo antes do desafio-chefe e acolhimento no erro. As frases citam o nome do perfil e os elementos da questão (maçãs, balões, moedas) quando possível, o que dá à criança a sensação de conversa real. A Tabela 5 no fim deste estudo traz exemplos antes e depois. Por fim, velocidade e tom passam a ser salvos por perfil de jogador, porque o ritmo ideal de uma criança de quatro anos não é o de um irmão de nove.

Custo: zero. Rede: nenhuma. Privacidade: intacta. Esforço: pequeno-médio. Impacto: alto.

5. Caminho B - Vozes neurais do sistema (grátis, sem código novo)

Este caminho é, na prática, um complemento do anterior. Os sistemas atuais já trazem vozes neurais sem custo: o Microsoft Edge expõe as vozes Online Natural da Azure (como a Francisca natural em português do Brasil) diretamente na speechSynthesis; o Windows oferece pacotes de vozes naturais instaláveis nas configurações; o macOS traz vozes Siri de alta qualidade; e o Android distribui o Google TTS com vozes modernas. Como todas aparecem na mesma lista de vozes que o aplicativo já consulta, a heurística do caminho A as encontra automaticamente, sem uma linha de código adicional.

As ressalvas são três. Primeiro, vozes marcadas como Online precisam de conexão ativa para sintetizar, embora a chamada continue sendo feita pelo sistema operacional, sem qualquer acesso do aplicativo ao tráfego; o motor deve detectar falha e cair silenciosamente para uma voz local. Segundo, o Firefox expõe apenas vozes locais do sistema em muitas plataformas, portanto a experiência varia entre navegadores, o que já acontece hoje e não piora. Terceiro, a disponibilidade depende do sistema do usuário: cabe ao aplicativo oferecer, na área dos

responsáveis, um botão ouvir amostra para a família escolher a melhor voz instalada. Com isso, o caminho B entrega o melhor custo-benefício do mercado: qualidade neural, custo zero e nenhuma mudança de arquitetura.

6. Caminho C - Síntese em nuvem (adiar para a era v3.x)

As APIs de nuvem produzem as vozes mais naturais disponíveis hoje, com estilos emocionais escolhíveis, como alegre e calmo. Para um produto infantil, porém, este caminho carrega exigências que o momento atual do projeto não justifica. A primeira é a chave de API: síntese em nuvem exige credenciais, e credenciais dentro de uma extensão são, por definição, expostas ao cliente; a arquitetura correta usa uma função serverless como proxy (o estudo de expansão de v2.2 já desenhou esse caminho com Supabase Edge Functions), o que pressupõe infraestrutura, custos variáveis e monitoramento. A segunda é privacidade e conformidade: embora apenas o texto das frases seja enviado, enviar qualquer dado de uma criança para serviços de terceiros exige base legal e consentimento dos responsáveis, além de avaliação dos termos de cada provedor para uso infantil (COPPA nos Estados Unidos, LGPD artigo 14 no Brasil). A terceira é a dependência de rede, que fere o pilar offline do produto.

Provedor	Vozes pt-BR de destaque	Preço indicativo	Observações para o produto
Google Cloud TTS	Neural2/Studio pt-BR	baixo a médio por milhão de caracteres	Qualidade excelente; Studio tem timbres mais naturais e preço bem maior
Microsoft Azure Speech	Francisca, Thalita, Elza (neurais)	médio por milhão de caracteres	Estilos falados (alegre/calmo); mesma família das vozes Natural do Edge
Amazon Polly	Camila, Luciana	médio por milhão de caracteres	Boa qualidade; contexto de fala conversacional
ElevenLabs	Clonagem e vozes comunitárias	assinatura mensal	Qualidade máxima percebida; custo por uso e termos exigem análise jurídica para crianças

Tabela 2. Provedores de síntese em nuvem (valores aproximados; confirmar preços atuais)

A recomendação técnica é clara: manter o caminho C fora do escopo imediato, mas deixar a porta aberta. O desenho futuro saudável é um modo opt-in na área dos responsáveis, com consentimento explícito, narração enviada como texto puro sem qualquer identificador da criança, cache local das frases já sintetizadas para reduzir custo e funcionamento parcial offline, e um limite mensal de caracteres configurável. Quando o ranking online da v3.x existir (com a infraestrutura do estudo anterior), o custo marginal de oferecer voz em nuvem cai muito, pois o proxy já estará lá.

7. Caminho D - Áudio humano pré-gravado (o calor máximo)

Nenhuma síntese supera, em afeto percebido, uma voz humana de verdade gravada com carinho. O caminho D propõe produzir um pacote de áudio oficial do Conta Comigo: uma atriz de voz (ou voz própria da equipe) gravando as falas centrais do jogo nas três saudações, nos elogios contextuais, nos incentivos e nos avisos, em interpretação cordial e calma. São cerca de oitenta a cento e vinte frases curtas. Compressão moderna Ogg Opus, mono, em qualidade de fala, ocupa poucos quilobytes por segundo, de modo que o pacote completo cabe em três a oito megabytes, perfeitamente aceitável dentro de uma extensão ou como complemento opcional.

A arquitetura recomendada é híbrida: as frases fixas tocam do arquivo gravado com latência zero e funcionamento offline, enquanto os trechos dinâmicos (números da questão, nomes dos itens) continuam na síntese local do sistema. Splicing de números gravados um a um soa recortado e deve ser evitado; a mistura frase gravada mais número sintético, com pequena pausa entre eles, soa natural e é técnica consolidada. O custo é único de produção (sessão de estúdio, edição e revisão), sem mensalidades e sem riscos de privacidade, pois nenhum dado sai do dispositivo. A manutenção exige regravação quando surgirem novos modos de jogo, o que é previsível e barato se a biblioteca de falas do caminho A for bem organizada.

Pacote estimado: 80 a 120 frases · 3 a 8 MB em Ogg Opus · latência zero · 100% offline.

8. Recomendação, riscos e próximos passos

A trilha recomendada equilibra ganho imediato, custo e risco. A Fase 1 (v2.4) entrega o caminho A completo: heurística de vozes naturais, prosódia por pontuação e fila de frases, biblioteca cordial contextual e preferências de voz por perfil, além do botão ouvir amostra na área dos responsáveis. É a maior melhoria percebida por unidade de esforço de todo este estudo e não altera nenhuma garantia de privacidade. A Fase 2 (v2.5) produz o pacote gravado do caminho D para as frases centrais em português, com detecção automática do pacote e queda elegante para síntese quando ausente; versões em inglês e espanhol podem vir depois conforme adesão. A Fase 3 (v3.x) avalia a nuvem com o proxy do ranking online, apenas opt-in e com consentimento, mantendo a voz local como padrão de fábrica.

Critério	A: local melhorado	B: vozes do sistema	C: nuvem	D: gravado
Qualidade	boa a muito boa	muito boa (quando presente)	excelente	excelente afeto
Custo	zero	zero	variável + infra	único de produção
Offline	sim	parcial	não	sim
Privacidade	nenhum dado sai	nenhum dado sai (do app)	requer consentimento	nenhum dado sai
Esforço	pequeno-médio	quase zero (herda A)	grande	médio
Recomendação	v2.4 agora	v2.4 (automático)	v3.x opt-in	v2.5 opcional

Tabela 3. Comparação dos quatro caminhos

Os riscos a monitorar são conhecidos e administráveis. Excesso de afeto pode soar artificial (vale testar com crianças reais e observar se a voz encanta ou distrai); festas sonoras frequentes podem cansar, por isso a intensidade é reservada a marcos; perfis sensoriais diversos pedem alternativa calma e controles manuais, que já existem; e qualquer migração para nuvem deve passar, antes, pela avaliação de privacidade descrita no estudo de expansão e segurança, incluindo política atualizada e registro do consentimento. Com essas guardas, a voz do Conta Comigo evolui de leitora de enunciados para aquilo que o produto sempre quis que ela fosse: uma amiga gentil que brinca de contar junto.

Situação	Fala atual	Proposta cordial (Fase 1)
Acerto comum	Isso mesmo!	Isso mesmo, Ana! Você juntou tudo direitinho.
Resposta rápida	(nenhuma)	Uau, que mente rápida! Você nem esperou a barra descer.
Erro	Quase! Tenta de novo.	Quase! Conta os morangos comigo, um por um. Eu sei que você consegue.
Combo	Combo x3!	Três seguidas! A raposa está dançando de alegria com você.
Fim de rodada	Você ganhou 12 estrelas!	Doze estrelinhas! Guardamos todas no seu céu. Até amanhã, campeã.

Tabela 4. Exemplos da biblioteca de falas (antes e depois)